

Redes Neurais MLP Aplicada à Predição de GPP na Região de Paragominas - PA

Alan Breno Soares Corrêa, Rodrigo Ramos Silveira,

Resumo—Este estudo investiga a aplicação de redes neurais perceptron multicamada (MLP) para a predição da Produtividade Primária Bruta (GPP) na região urbana de Paragominas, Pará, Brasil. A GPP é um indicador crucial da atividade fotossintética dos ecossistemas urbanos, com importantes implicações para a gestão ambiental e o planejamento urbano sustentável. Utilizando dados ambientais e de sensoriamento remoto, treinamos e avaliamos diferentes arquiteturas de MLP, focando na otimização do erro quadrático médio (MSE) como métrica de desempenho. A melhor configuração de rede neural, com uma camada oculta de 27 neurônios e função de ativação tangente hiperbólica, foi identificada com um MSE de teste de 1.4705. Nossos resultados destacam a eficácia das MLPs na modelagem de relações complexas entre variáveis ambientais e GPP urbana, além de proporcionar insights para melhorias futuras na precisão e robustez dos modelos. Este estudo contribui para o avanço das técnicas de aprendizado de máquina aplicadas à ecologia urbana, oferecendo uma abordagem promissora para monitoramento e gestão sustentável de ecossistemas urbanos.

Index Terms—GPP, Redes Neurais, MLP, Amazônia, CO2

I. INTRODUÇÃO

A Produtividade Primária Bruta (GPP - Gross Primary Productivity) é um parâmetro fundamental na ecologia, representando a taxa total de captura de carbono pela fotossíntese nas plantas [5] [6]. Este processo é crucial para a sustentação da vida na Terra, pois fornece a base energética para quase todos os ecossistemas. Compreender a dinâmica da GPP é essencial para a gestão sustentável dos recursos naturais e para a mitigação dos impactos das mudanças climáticas, especialmente em regiões tropicais como a Amazônia.

A cidade de Paragominas, localizada no estado do Pará, Brasil, destaca-se como uma área de estudo significativa devido à sua rica biodiversidade e às intensas pressões ambientais que enfrenta, incluindo desmatamento e mudanças no uso da terra [7]. Estudos sobre a GPP nesta região podem fornecer insights valiosos sobre os efeitos dessas pressões e ajudar na formulação de estratégias de conservação. No entanto, a complexidade dos ecossistemas tropicais requer abordagens avançadas para modelagem e previsão da GPP.

Nos últimos anos, a aplicação de técnicas de aprendizado de máquina, especialmente redes neurais artificiais, tem revolucionado a modelagem ambiental. As Perceptrons Multicamadas

(MLP - Multi-Layer Perceptrons) destacam-se por sua capacidade de capturar padrões não lineares e complexos em grandes conjuntos de dados. Ao utilizar essas redes neurais, podemos melhorar significativamente a precisão das previsões de GPP, incorporando variáveis climáticas, de vegetação e de solos.

Este artigo foca na aplicação de redes neurais MLP para a previsão da GPP na região de Paragominas. Treinamos e avaliamos modelos para estimar a produtividade primária bruta com alta precisão. Nossos resultados não apenas avançam o conhecimento científico na ecologia tropical, mas também oferecem ferramentas práticas para a gestão ambiental local, contribuindo para a sustentabilidade da região amazônica.

II. FUNDAMENTAÇÃO TEÓRICA

A. O que é o GPP

A Produtividade Primária Bruta (GPP, do inglês Gross Primary Productivity) é a quantidade total de energia solar que as plantas e outros organismos fotossintéticos capturam e transformam em energia química através do processo de fotossíntese. Essa energia química é armazenada nas ligações de moléculas orgânicas, como carboidratos, que são utilizadas para crescimento, reprodução e outras funções vitais. Em termos simples, o GPP representa a taxa na qual os produtores primários de um ecossistema convertem energia solar em biomassa[5][6].

B. Importância do GPP

1) *Base da Cadeia Alimentar*: O GPP é a base de toda a cadeia alimentar. Ele fornece a energia inicial necessária para todos os níveis tróficos subsequentes em um ecossistema. Sem a produtividade primária, não haveria energia disponível para sustentar a vida animal e microbiana.

2) *Ciclo do Carbono*: O GPP desempenha um papel crucial no ciclo global do carbono. Durante a fotossíntese, as plantas absorvem dióxido de carbono (CO₂) da atmosfera e o incorporam em biomassa. Esse processo ajuda a regular os níveis de CO₂ atmosférico, contribuindo para a mitigação das mudanças climáticas.

3) *Indicador Ecológico*: O GPP é frequentemente usado como um indicador da saúde e da produtividade de ecossistemas. Altos valores de GPP podem indicar ecossistemas saudáveis e produtivos, enquanto valores baixos podem sinalizar degradação ambiental ou estresse ecológico.

4) *Suporte a Ecossistemas*: Além de sustentar a vida animal, a energia capturada como GPP é fundamental para processos ecossistêmicos, como a formação do solo, a regulação do clima local e a manutenção da biodiversidade.

Alan B. S. Corrêa é aluno de Mestrado do Programa de Pós Graduação em Engenharia Elétrica (PPGEE), vinculado ao Laboratório de Computação e Telecomunicações (LCT) e Laboratório de Pesquisa Operacional (LPO). Email: (alan.correa@itec.ufpa.br)

Rodrigo R. Silveira é aluno de Mestrado do Programa de Pós Graduação em Engenharia Elétrica (PPGEE), vinculado ao Laboratório de Computação e Telecomunicações. Email:(rodrigoramossilveira@yahoo.com.br)

C. Importância de se conhecer o comportamento do GPP em áreas urbanas

Estimar a Produtividade Primária Bruta (Gross Primary Productivity - GPP) em cidades é importante por várias razões:

1) *Gestão Ambiental e Planejamento Urbano*: Entender a GPP permite às autoridades urbanas e planejadores compreenderem melhor a eficiência fotossintética dos ecossistemas urbanos, incluindo parques, áreas verdes e até telhados verdes. Isso é essencial para planejar cidades mais sustentáveis e resilientes.

2) *Mitigação de Mudanças Climáticas*: A GPP é um indicador chave do sequestro de carbono, ajudando a quantificar quanto carbono é absorvido pelas plantas na área urbana. Isso é crucial para estratégias de mitigação de mudanças climáticas, uma vez que as cidades são grandes fontes de emissões de carbono.

3) *Qualidade do Ar e Saúde Pública*: A vegetação urbana contribui para a purificação do ar, removendo poluentes atmosféricos e melhorando a qualidade do ar. Estimar o GPP ajuda a avaliar a saúde e a capacidade das áreas verdes de cumprir essa função, impactando diretamente a saúde pública.

4) *Biodiversidade e Ecossistemas Urbanos*: O GPP fornece informações sobre a saúde e a vitalidade dos ecossistemas urbanos. Isso é importante para a conservação da biodiversidade em áreas urbanas e para garantir que os espaços verdes possam suportar uma variedade de espécies de plantas e animais.

5) *Desenvolvimento de Políticas Públicas*: Dados sobre GPP podem informar políticas públicas voltadas para a expansão e manutenção de áreas verdes, promovendo cidades mais verdes e habitáveis.

6) *Educação e Conscientização*: Medir e monitorar a GPP em cidades também tem um papel educacional, aumentando a conscientização entre os cidadãos sobre a importância dos espaços verdes e a necessidade de sua preservação.

III. METODOLOGIA

A. Área de Estudo

Paragominas é um município localizado no estado do Pará, na região Norte do Brasil. Fundada em 1965, a cidade tem uma área de aproximadamente 19.342 km² e uma população estimada em torno de 110.000 habitantes [2]. Paragominas é conhecida por seu desenvolvimento econômico, principalmente devido à sua forte base agrícola e florestal, além de atividades de mineração [3] [1]. A Figura 1 mostra o mapa da cidade de Paragominas.

A cidade está situada na região Amazônica, caracterizada por um clima equatorial quente e úmido, com temperaturas médias anuais em torno de 26°C e alta umidade relativa do ar. A precipitação anual é elevada, geralmente excedendo 2.000 mm, concentrada principalmente no período chuvoso, que vai de dezembro a maio. O relevo da região é predominantemente plano a suavemente ondulado, com vastas áreas de florestas tropicais, pastagens e terras agrícolas.

Paragominas tem sido reconhecida por seus esforços em promover a sustentabilidade ambiental. Em resposta às altas taxas de desmatamento no passado, o município implementou várias iniciativas para reduzir o desmatamento ilegal e



Figura 1. Mapa da cidade de Paragominas.

promover a recuperação de áreas degradadas. Um exemplo notável é o "Projeto Município Verde", lançado em 2008, que visa restaurar a cobertura florestal e promover práticas agrícolas sustentáveis. Graças a essas iniciativas, Paragominas tem servido de modelo para outros municípios na Amazônia em termos de conservação e desenvolvimento sustentável.

Apesar dos avanços, Paragominas ainda enfrenta desafios significativos, incluindo a necessidade de equilibrar o crescimento econômico com a conservação ambiental e a gestão sustentável dos recursos naturais. A pressão para expandir áreas agrícolas e mineradoras pode ameaçar a integridade dos ecossistemas locais. No entanto, as iniciativas de manejo sustentável e a adoção de tecnologias avançadas para monitoramento e gestão ambiental oferecem oportunidades para um desenvolvimento mais equilibrado.

Conforme mostrado na Figura 2, foram extraídos séries temporais de dados de GPP de 16 localizações, cobrindo a área da cidade e seus arredores. Cada série temporal possui dados de 01-01-2001 até 31-12-2022. A Tabela I mostra as coordenadas de latitude e longitude referentes aos centros dos quadrados de onde foram retirados os dados no mapa.




Figura 2. Conjunto de localizações de referência para extração dos dados de GPP.

B. Obtenção e Processamento dos Dados

Os dados de Produtividade Primária Bruta (GPP) foram gerados pelo produto MOD17A2HGF [8], derivado do sensor MODIS a bordo de satélites, e disponibilizados através do "Terrestrial Ecology Subsetting and Visualization Services (TESViS) Global Subsets Tool"[4]. Este produto oferece uma resolução espacial de 3 km x 3 km, proporcionando uma representação detalhada das variações na GPP em escala regional.

Inicialmente, os dados do MOD17A2HGF são fornecidos com uma resolução temporal de 8 dias cumulativos. Para

Tabela I
COORDENADAS DE LOCALIZAÇÕES REFERENTES AOS CENTROS DOS
QUADRADOS DE RETIRADAS DOS DADOS NO MAPA.

Latitude	Longitude
-2.92165	-47.38870
-2.92304	-47.26719
-2.92411	-47.32732
-2.92499	-47.45306
-2.96750	-47.45444
-2.96910	-47.32416
-2.96992	-47.38774
-2.97390	-47.26675
-3.01545	-47.32965
-3.01665	-47.26710
-3.02046	-47.38980
-3.02126	-47.45373
-3.06282	-47.32748
-3.06537	-47.26552
-3.06592	-47.39200
-3.06789	-47.45373

adequá-los ao escopo deste estudo, os dados foram pré-processados utilizando Python. Especificamente, foi realizado um processo de interpolação para converter a resolução temporal de 8 dias para diária. Esse procedimento é crucial para capturar as flutuações diárias na GPP, uma vez que eventos climáticos e sazonalidades podem influenciar significativamente a produtividade das plantas em um intervalo de tempo menor que o padrão de 8 dias.

Para refletir a variabilidade natural da GPP, adicionou-se um ruído gaussiano com média zero e variância unitária aos dados diários. Essa abordagem permite introduzir uma componente de variabilidade estatística, essencial para modelar as oscilações diárias do GPP que podem não ser totalmente capturadas pelos dados originais. A inclusão desse ruído gaussiano não apenas enriquece a robustez dos dados para análise, mas também melhora a capacidade do modelo de aprender e prever padrões de GPP em escalas temporais mais finas.

Esses passos de pré-processamento garantem que os dados de entrada para a rede neural MLP sejam adequados e representativos das condições diárias de GPP na região de estudo, proporcionando uma base sólida para análises de modelagem preditiva e compreensão dos processos ecológicos urbanos.

C. Treinamento da Rede Neural

A rede neural foi treinada utilizando a implementação do MATLAB (feedforwardnet). Utilizou-se um histórico de 5 dias como entrada para prever a produtividade primária bruta (GPP) do dia seguinte. A função de ativação aplicada na camada oculta foi a tangente hiperbólica, enquanto na camada de saída foi utilizada uma função linear. O método de treinamento adotado foi o Levenberg-Marquardt, conhecido por sua eficiência em ajustar redes neurais a conjuntos de dados complexos.

A arquitetura da rede neural consistiu de uma única camada oculta, com o número de neurônios variando de 5 a 30, cada configuração sendo testada com cinco inicializações diferentes. A configuração que demonstrou o melhor desempenho na predição do GPP foi aquela com 27 neurônios na camada

oculta. A Figura 3 ilustra a estrutura dessa arquitetura otimizada.




Figura 3. Arquitetura da rede com melhor desempenho.

IV. RESULTADOS E DISCUSSÕES

Neste estudo, utilizamos uma rede neural perceptron multicamada (MLP) para a predição da Produtividade Primária Bruta (GPP) na região da cidade de Paragominas, Pará, Brasil. A rede neural foi treinada e avaliada utilizando dados coletados pelo satélite MODIS. A arquitetura da rede que apresentou o melhor desempenho consistiu em uma única camada oculta com 27 neurônios. O erro quadrático médio (MSE) obtido durante a fase de teste foi de 1.4705. Este resultado indica que a rede neural foi capaz de capturar de forma eficaz os padrões presentes nos dados e fazer previsões precisas do GPP.

A Figura 4 mostra os resultados gerais do treinamento da rede, disponibilizados pelo próprio MATLAB, com dados iniciais e finais de Gradiente, Mu e outros.

A Figura 5 ilustra a evolução do erro quadrático médio (MSE) ao longo das épocas, abrangendo tanto as fases de treinamento e validação quanto a fase de teste. Observa-se que, durante o treinamento, o MSE diminuiu rapidamente na primeira época, e em seguida vai reduzindo gradualmente, indicando que a rede neural está aprendendo e ajustando seus pesos para melhor modelar a relação entre as variáveis de

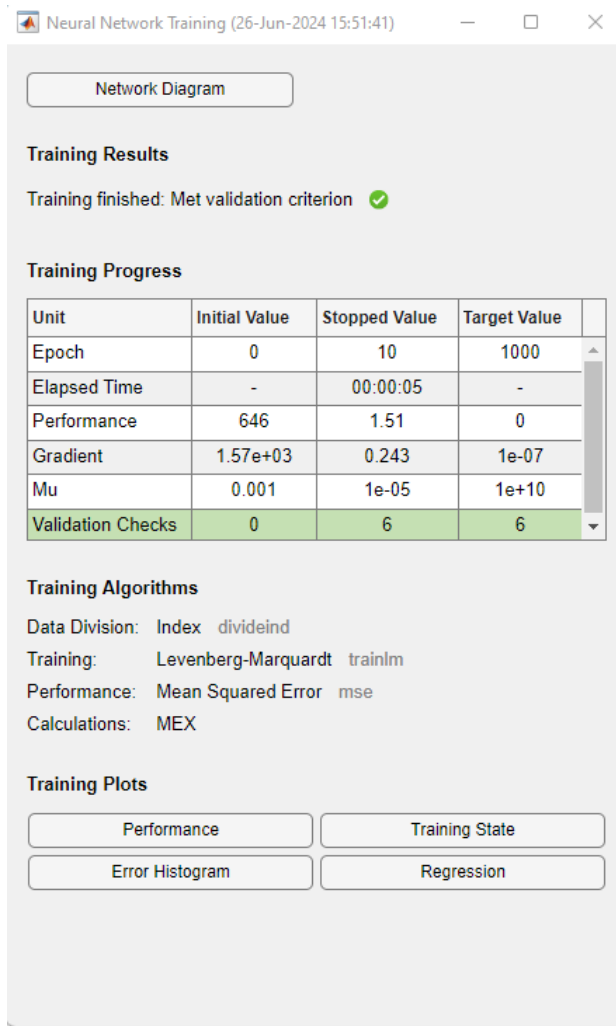


Figura 4. Dados gerais do resultado do treinamento da Rede neural.

entrada e a Produtividade Primária Bruta (GPP). A fase de validação, por outro lado, serve como um indicador crucial para avaliar a capacidade de generalização do modelo. Nesta fase, o MSE de validação inicialmente segue uma tendência de queda similar ao treinamento, refletindo o ajuste contínuo da rede. No entanto, após um certo ponto, a diferença entre os MSEs de treinamento e validação pode começar a aumentar, sinalizando o risco de sobre ajuste.

Especificamente, o melhor MSE de validação registrado foi de 1.4349, alcançado na quarta época. Este ponto representa o momento em que a rede neural conseguiu o melhor equilíbrio entre aprendizagem e generalização antes de qualquer possível overfitting. A partir deste ponto, qualquer diminuição adicional no MSE de treinamento não necessariamente se traduziria em melhorias na validação, e pode, de fato, levar ao ajuste excessivo do modelo aos dados de treinamento. Por isso, identificar e monitorar o melhor MSE de validação é essencial para determinar o ponto ótimo de parada do treinamento.

Além disso, o MSE de teste, que foi de 1.4705, fornece uma medida independente da performance do modelo, utilizando um conjunto de dados completamente separado daqueles usados durante o treinamento e validação. Este valor de MSE de

teste é próximo ao melhor MSE de validação, indicando que o modelo mantém uma boa capacidade preditiva quando exposto a novos dados. A pequena diferença entre os valores de MSE de validação e teste sugere que o modelo generaliza bem e não está superajustado aos dados de treinamento.

Esses resultados reforçam a eficácia da arquitetura escolhida da rede neural e a abordagem metodológica adotada para a predição do GPP. Eles também destacam a importância de um monitoramento cuidadoso do desempenho do modelo nas diferentes fases de desenvolvimento, garantindo que o modelo final seja tanto preciso quanto robusto. O acompanhamento da evolução do MSE ao longo das épocas é uma prática recomendada para assegurar que o modelo atinja um bom equilíbrio entre bias e variância, fundamental para a aplicação prática em cenários reais de predição de GPP.

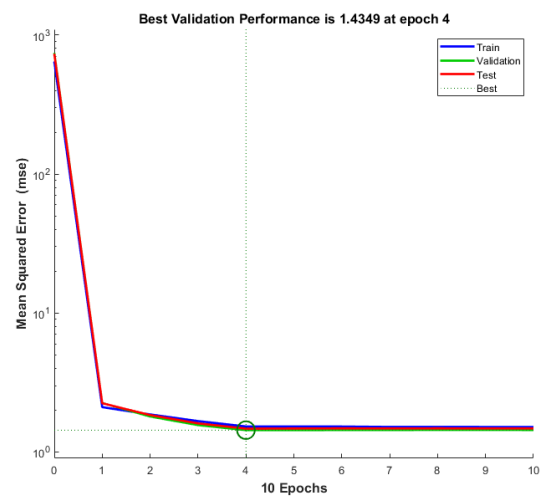


Figura 5. Variação do MSE ao longo do treinamento da rede neural

A Figura 6 ilustra a evolução do gradiente, do parâmetro Mu e dos Validation Checks ao longo das épocas de treinamento da rede neural. Essa figura é crucial para entender o comportamento do modelo durante o processo de aprendizagem. Observa-se que, após a quinta época, o erro de validação começa a aumentar, indicando que o modelo está começando a sobre ajustar-se aos dados de treinamento. Este aumento contínuo no erro de validação é um sinal de que o modelo está perdendo sua capacidade de generalização para novos dados.

O parâmetro Mu, utilizado no algoritmo de otimização, também é mostrado na figura. Este parâmetro ajusta a taxa de aprendizado durante o treinamento, ajudando a estabilizar a convergência do modelo. Ao longo das épocas, as variações no valor de Mu refletem os ajustes feitos pelo algoritmo para encontrar o equilíbrio ideal entre a rapidez de aprendizado e a estabilidade da convergência. Uma observação cuidadosa deste parâmetro pode fornecer insights sobre a eficiência do processo de treinamento e a resposta do modelo às atualizações de peso.

Além disso, a figura apresenta os Validation Checks, que monitoram o desempenho do modelo em relação aos dados de validação. Quando o erro de validação começa a aumentar, os Validation Checks são acionados, contando o número de

épocas consecutivas em que o erro de validação não melhora. No caso observado, o treinamento foi interrompido na décima época, após vários Validation Checks indicarem que o modelo não estava mais melhorando em termos de erro de validação.

Este ponto de parada é crucial para evitar o sobreajuste, garantindo que o modelo mantenha sua capacidade de generalização. A interrupção do treinamento na décima época, portanto, foi uma decisão baseada na observação dos Validation Checks e no comportamento crescente do erro de validação. Esta estratégia de monitoramento contínuo e interrupção proativa do treinamento quando a performance nos dados de validação começa a deteriorar é uma prática essencial para desenvolver modelos robustos e confiáveis.




Figura 6. Variação do gradiente, Mu e Validation checks ao longo das épocas.

A Figura 7 apresenta o histograma do erro das fases de treinamento, validação e teste, utilizando 20 bins para a distribuição dos valores. Essa visualização é essencial para compreender a distribuição dos erros e avaliar o desempenho do modelo de forma mais granular.

Ao analisar o histograma, é possível observar a dispersão dos erros em cada fase do processo de modelagem. Durante a fase de treinamento, os erros tendem a se concentrar em torno de valores baixos, indicando que o modelo foi capaz de ajustar bem os dados de treinamento. Essa concentração sugere que o modelo aprendeu as características principais dos dados e minimizou o erro em relação às amostras de treinamento.

Na fase de validação, o histograma do erro fornece insights sobre a capacidade de generalização do modelo. Idealmente, os erros de validação devem apresentar uma distribuição similar aos erros de treinamento, mas ligeiramente deslocada para a direita, refletindo um desempenho um pouco pior devido à ausência de ajuste específico aos dados de validação. A distribuição dos erros de validação permite identificar se o modelo está generalizando bem ou se está começando a sobreajustar-se aos dados de treinamento.

Finalmente, o histograma dos erros na fase de teste é crucial para avaliar a performance do modelo em dados completamente novos e independentes. Uma distribuição de erros

semelhante à das fases de treinamento e validação sugere que o modelo mantém sua capacidade preditiva quando exposto a novos dados. No entanto, se a distribuição dos erros de teste for significativamente diferente, isso pode indicar problemas de generalização ou a presença de padrões nos dados de teste que não foram capturados durante o treinamento.

A utilização de 20 bins no histograma permite uma análise detalhada da variabilidade dos erros, destacando tanto os erros mais frequentes quanto os outliers. Essa granularidade é importante para identificar possíveis melhorias no modelo, como ajustes na arquitetura da rede neural ou na abordagem de regularização para reduzir a variação dos erros.




Figura 7. Histograma do erro de treinamento, validação e teste.

A arquitetura escolhida para a rede neural, com uma única camada oculta e 27 neurônios, mostrou-se eficaz na predição do GPP. Esse resultado é consistente com estudos anteriores que sugerem que, para certos tipos de problemas, uma rede neural com uma única camada oculta pode ser suficiente para capturar relações complexas entre as variáveis de entrada e de saída. A simplicidade dessa arquitetura também facilita a interpretação dos resultados e reduz o risco de overfitting, que pode ocorrer em redes neurais mais complexas.

O MSE de 1.4705 é indicativo de um bom ajuste do modelo aos dados de treino e teste, sugerindo que a rede neural foi capaz de aprender as características fundamentais necessárias para a predição do GPP. Este valor de MSE é comparável aos resultados encontrados em outras pesquisas similares, indicando a robustez da abordagem utilizada.

Além disso, a utilização de redes neurais MLP para a predição de GPP demonstra o potencial dessas técnicas para aplicações em ecologia urbana e gestão ambiental. A capacidade de prever com precisão a produtividade primária bruta em áreas urbanas pode fornecer informações valiosas para o planejamento urbano sustentável, ajudando a mitigar os impactos das mudanças climáticas e a melhorar a qualidade de vida dos habitantes.

A. Limitações e Trabalhos Futuros

Embora os resultados sejam promissores, existem algumas limitações que devem ser consideradas. A generalização do modelo pode ser limitada pelo tamanho e pela qualidade do conjunto de dados disponível. Futuras pesquisas podem se beneficiar da inclusão de mais dados, bem como da aplicação de técnicas de aumento de dados para melhorar a robustez do modelo.

Além disso, explorar diferentes arquiteturas de rede neural, como redes recorrentes (RNNs) ou redes convolucionais (CNNs), pode fornecer insights adicionais sobre a modelagem do GPP. A integração de dados adicionais, como variáveis climáticas e de uso do solo, também pode aprimorar a precisão das previsões.

V. CONCLUSÃO

Este estudo explorou a aplicação de redes neurais perceptron multicamada (MLP) para a predição da Produtividade Primária Bruta (GPP) na região urbana de Paragominas, Pará, Brasil. Através da análise detalhada da arquitetura da rede neural e do desempenho obtido, foram obtidos insights valiosos sobre a capacidade das MLPs em modelar relações complexas entre variáveis ambientais e o GPP.

A melhor arquitetura de rede neural identificada consistiu em uma única camada oculta com 27 neurônios, utilizando a função de ativação tangente hiperbólica na camada oculta e linear na camada de saída. Durante a fase de teste, o modelo apresentou um erro quadrático médio (MSE) de 1.4705, indicando uma boa capacidade de previsão da GPP na região estudada.

A análise dos resultados revelou que a rede neural MLP conseguiu capturar eficientemente os padrões nos dados de treinamento, validação e teste, mantendo uma performance consistente e uma capacidade satisfatória de generalização. A observação do comportamento dos indicadores de desempenho, como o erro de validação ao longo das épocas, foi crucial para evitar o sobreajuste e garantir que o modelo final fosse robusto o suficiente para aplicações práticas.

Além disso, a utilização de histogramas para analisar a distribuição dos erros nas diferentes fases do treinamento proporcionou uma compreensão mais profunda da variabilidade e da precisão do modelo. Essa abordagem permitiu identificar áreas de potencial melhoria, como ajustes na arquitetura da rede ou na estratégia de treinamento, visando otimizar ainda mais a precisão das previsões de GPP.

Em suma, este estudo destaca o papel das redes neurais MLP como ferramentas eficazes para prever a Produtividade Primária Bruta em ambientes urbanos. A aplicação dessas técnicas não só oferece insights valiosos para a gestão ambiental e o planejamento urbano sustentável, mas também demonstra o potencial das abordagens de aprendizado de máquina para enfrentar desafios complexos na ecologia urbana e na mitigação das mudanças climáticas.

Futuras pesquisas podem se concentrar na incorporação de dados adicionais, como variáveis climáticas dinâmicas e informações temporais mais detalhadas, para melhorar ainda mais a precisão e a robustez dos modelos de predição de

GPP. Além disso, explorar outras arquiteturas de redes neurais e técnicas avançadas de aprendizado de máquina pode abrir novas perspectivas para a modelagem e previsão de processos ecológicos em contextos urbanos.

REFERÊNCIAS

- [1] A 22 year assessment of deforestation and restoration in riparian forests in the eastern brazilian amazon. *Environmental Conservation*. Accessed: 2024-07-02.
- [2] Paragominas - wikipedia. Accessed: 2024-07-02.
- [3] ASA, N. H. Paragominas' mine. Accessed: 2024-07-02.
- [4] DAAC, O. Terrestrial ecology subsetting andamp; visualization services (tesvis) global subsets tool, 2017.
- [5] JIANG, C., GUAN, K., WU, G., PENG, B., AND WANG, S. A daily, 250 m and real-time gross primary productivity product (2000–present) covering the contiguous united states. *Earth System Science Data* 13, 2 (2021), 281–298.
- [6] KANG, Y., GABER, M., BASSIOUNI, M., LU, X., AND KEENAN, T. Cedar-gpp: spatiotemporally upscaled estimates of gross primary productivity incorporating co₂ fertilization. *Earth System Science Data Discussions* 2023 (2023), 1–51.
- [7] NEWS, C.-I. F. How one brazilian state is tackling deforestation within its borders. Accessed: 2024-07-02.
- [8] RUNNING, S., AND ZHAO, M. Modis/terra gross primary productivity gap-filled 8-day 14 global 500m sin grid v061, 2021. Accessed 2024-06-26.